

Percepatan Inferensi CNN Super-Resolution melalui Reduksi Spasial GPU: Studi Lintas Platform pada Arsitektur Memori Terpadu dan Diskret

M. Hamdani Ilham Latjoro, Adnan

Departemen Teknik Informatika, Fakultas Teknik

Universitas Hasanuddin

Makassar, Indonesia

latjoromhi25d@student.unhas.ac.id, adnan@unhas.ac.id

Abstrak—Lapisan dekonvolusi terakhir FSRCNN sekaligus menjadi bottleneck komputasi dan sumber kesalahan kebenaran: akumulasi multi-thread CPU yang naif memicu race condition dan merusak keluaran secara tidak reproducible. Kami memindahkan lapisan tersebut ke kernel CUDA per-kanal yang terisolasi, diikuti satu tahap reduksi paralel, sehingga race hilang secara konstruktif, lalu mengevaluasinya pada dua platform yang berbeda secara arsitektural: NVIDIA GB10 Grace Blackwell Superchip dengan memori terpadu, dan desktop Intel i9-14900K dengan RTX 4090 melalui PCIe. Pada keduanya, keluaran reduksi spasial versi CPU maupun GPU identik byte per byte dengan referensi deterministik terverifikasi di setiap konfigurasi yang diuji, dan keluaran GPU identik hingga tingkat bit antara kedua platform meskipun arsitektur set instruksi host dan mikroarsitektur GPU-nya berbeda. Grid 32 kali 8 yang selaras warp tercepat di kedua platform, dan profiling per-kernel melokalisasi seluruh perolehan pada kernel dekonvolusi, sebagaimana diprediksi penjelasan memory coalescing. Percepatan terhadap konfigurasi CPU terbaik yang kebenarannya terverifikasi mencapai 1.46 kali pada GB10, pada 31.5 frame per detik, dan 1.63 kali pada RTX 4090, pada 27.6 frame per detik. Profiling juga mengidentifikasi satu batas arsitektural bagi biaya pola ini: determinisme menelan 4.6 persen waktu Layer 8 GPU pada GB10 tetapi hanya 0.6 persen pada RTX 4090, bergantung pada apakah buffer privat muat di last-level cache, sementara transfer device ke host berjalan sebaliknya dan 4.74 kali lebih cepat pada memori terpadu.

Kata Kunci—Super-resolution, FSRCNN, offloading GPU, CUDA, reduksi spasial, Grace Blackwell, multicore asimetris, kesamaan bit.

I. PENDAHULUAN

Perangkat keras AI kelas edge maupun workstation semakin banyak memakai SoC yang di dalamnya CPU multicore dan GPU hidup berdampingan pada interkoneksi berkecepatan tinggi [20], [21]. CNN super-resolution bergerak seiring dengan itu. Formulasi awal [9] digantikan FSRCNN [2], yang menunda ekstraksi fitur ke ruang resolusi rendah dan baru melakukan upscaling pada lapisan dekonvolusi terakhir.

Tahap terakhir itu (Layer 8) memikul biaya yang tidak sebanding: untuk upscaling $2\times$ ia menerapkan kernel 9×9 pada 56 kanal lalu mengakumulasikannya menjadi satu bidang keluaran. Memparalelkannya di CPU multicore menghadirkan dilema. Akumulasi bersama secara naif menimbulkan race dan

merusak keluaran secara tidak reproducible [1], sedangkan mutex atau atomic membawa contention yang mahal. Pola privatisasi lalu reduksi menghindari keduanya dengan menulis ke buffer privat per kanal dan mereduksinya pada tahap deterministik terpisah, dengan harga tambahan trafik sebesar 43.3 MiB.

Kami memindahkan dekonvolusi dan reduksi tersebut ke CUDA sambil memparalelkan Layer 1–7 di inti-inti CPU. Kontribusi kami ada empat. (i) *Pergeseran profil biaya di GPU*: privatisasi lalu reduksi adalah pola klasik, bukan algoritma baru, tetapi memindahkannya ke GPU mengubah biayanya secara kualitatif. Trafik buffer privat yang menelan 8–18% waktu wall-clock CPU turun menjadi 4.6% (GB10) dan 0.6% (RTX 4090) dari waktu Layer 8 GPU, sementara keluarannya tetap bit-exact. Kami membingkainya sebagai persoalan bandwidth dan paralelisme, bukan kapasitas, sebab platform utama kami berbagi satu kolam memori antara CPU dan GPU sehingga buffer-nya tidak berpindah ke mana pun; yang berpindah hanyalah komputasi di atasnya. (ii) *Konfigurasi grid selaras warp*: blok 32×8 memaksimalkan coalescing untuk akses row-major pada dekonvolusi, memangkas waktu kernel sebesar 23.4% dan 17.4%, dengan profiling per-kernel yang melokalisasi seluruh perolehan pada dekonvolusi sesuai prediksi penjelasannya. (iii) *Determinisme lintas platform*: keluaran GPU identik byte per byte dengan baseline CPU pada setiap konfigurasi yang diuji di kedua platform, dan identik hingga tingkat bit antar keduanya, mencakup dua ISA host dan dua generasi GPU, pada $1.46\times$ dan $1.63\times$ terhadap konfigurasi CPU deterministik terbaik masing-masing platform. (iv) *Batas arsitektural bagi biaya pola ini*: reduksinya terikat bandwidth, dan biayanya bergantung pada apakah buffer privat muat di last-level cache. Biaya itu nyaris nol pada RTX 4090, yang L2-nya menampung buffer tersebut, dan $10\times$ lebih mahal pada GB10, yang harus melakukan streaming pada 95% dari puncak memorinya. Transfer device ke host berjalan sebaliknya, $4.74\times$ lebih cepat pada memori terpadu.

II. LATAR BELAKANG DAN ARSITEKTUR BASELINE

A. Penelitian Terkait

Super-resolution berbasis CNN berkembang dari formulasi awal [9] ke FSRCNN [2], dan makin banyak diterapkan pada SoC heterogen CPU+GPU [20], [21]. Yang paling dekat dengan kami, Annisa dkk. [1] mengarakterisasi race Layer 8 yang sama pada Orange Pi 5 dengan sekuens Suzie yang sama, dan menemukan korupsi lebih parah pada afinitas inti LITTLE; tujuan mereka mengarakterisasi korupsi itu, bukan memperbaikinya, dan kami tidak membandingkan angka percepatan karena perangkat keras kami berbeda beberapa orde dalam jumlah maupun kelas inti. Privatisasi lalu reduksi adalah pola klasik; kontribusi kami adalah mengadopsinya sebagai baseline CPU bebas race lalu memindahkannya ke GPU, yang mengubah profil biayanya sambil mempertahankan bit-exactness. Inferensi CNN menskala baik pada ARM big.LITTLE bila dijadwalkan dengan benar [3], sehingga baseline GB10 kami bukan lawan yang lemah. Pustaka seperti cuDNN [12] menargetkan konvolusi secara luas tetapi bukan tata letak bebas race ini; klaim kami hanya soal kendali atas tata letak memori, bukan keunggulan kecepatan. Overhead PCIe pada GPU diskret sudah terdokumentasi baik [7], yang melatarbelakangi perbandingan memori terpadu versus diskret, dan penelitian terbaru mengarakterisasi memori fisik terpadu secara langsung [21]. Keruntuhan penjadwalan pada RTX 4090 yang kami amati berkaitan dengan penelitian tentang penjadwalan CPU asimetris [4], [5]; di sana kami menyumbang sebuah pengamatan, bukan mekanisme.

B. Arsitektur FSRCNN

FSRCNN terdiri atas delapan lapisan: Feature Extraction (Layer 1), Shrinking (Layer 2), empat lapisan Mapping (Layer 3–6), Expanding (Layer 7), dan Deconvolution (Layer 8). Untuk sekuens masukan 176×144 yang diskalakan $2 \times$, Layer 1–7 seluruhnya bekerja di ruang resolusi rendah dan menghasilkan 56 peta fitur. Layer 8 kemudian melakukan upscaling. Ia mengambil ke-56 kanal itu, menerapkan transposed convolution 9×9 [15] dengan stride 2, lalu mereduksinya menjadi satu frame luminansi YUV 352×288 .

C. Varian Baseline

Kami membandingkan tiga varian. **V0 (OpenMP CPU naif)** membuat thread pekerja Layer 8 mengakumulasi keluaran dekonvolusi langsung ke satu buffer bersama `img_filt_r_8`; dengan lebih dari satu thread, jejak kernel yang saling tumpang tindih menyebabkan race baca-modifikasi-tulis tanpa sinkronisasi dan keluaran menjadi rusak, yakni kelas bug yang justru menjadi sasaran detektor dinamis seperti ThreadSanitizer [13]. **V1 (reduksi spasial, CPU)** menghilangkan race dengan buffer privat `all_tmp[56 × 352 × 288]` bertipe double (43.3 MiB); setiap kanal menulis pada offset terisolasi sendiri, lalu tahap kedua menjumlahkan ke-56 kanal per piksel. Kedua tahap paralel, tetapi pada sumbu yang berbeda: dekonvolusi pada kanal, reduksi pada piksel keluaran. Reduksinya tidak memerlukan sinkronisasi karena setiap piksel keluaran ditulis oleh tepat satu thread,

dan tetap deterministik karena thread tersebut menjumlahkan ke-56 sukunya dalam urutan kanal yang tetap, terlepas dari bagaimana penjadwalannya. **V2 (reduksi spasial GPU, yang diusulkan)** mempertahankan Layer 1–7 pada thread OpenMP CPU dan memindahkan dekonvolusi serta reduksi Layer 8 ke CUDA.

III. IMPLEMENTASI REDUKSI SPASIAL GPU

A. Target Perangkat Keras: GB10 dan RTX 4090

Platform utama kami adalah ASUS Ascent GX10 [17] dengan NVIDIA GB10 Grace Blackwell Superchip [16], yang kluster CPU-nya memakai teknologi DynamIQ big.LITTLE dari Arm [18]. Bagian VI memvalidasi silang pada platform kedua yang berbeda secara arsitektural: desktop Intel Core i9-14900K dengan RTX 4090 (Ada Lovelace [19]), yang memori CPU dan GPU-nya terpisah secara fisik dan terhubung PCIe alih-alih berbagi kolam terpadu NVLink-C2C seperti GB10. Tabel I membandingkan keduanya.

TABEL I
SPESIFIKASI PERANGKAT KERAS: GB10 (GX10) VS. DESKTOP RTX 4090

Komponen	GB10 (ASUS GX10)	Desktop RTX 4090
CPU	ARM v9.2-A DynamIQ 20 inti 10 × X925 P + 10 × A725 E @ 3.90/2.81 GHz, tanpa SMT	Intel Core i9-14900K 8 P-core (dgn HT) + 16 E-core 24C/32T, hingga 6.0 GHz
GPU	NVIDIA Blackwell, sm_121	NVIDIA Ada Lovelace, sm_89
Inti GPU	6,144 CUDA, 48 SM, Tensor Gen5	16,384 CUDA, 128 SM [19]
Memori	128 GB LPDDR5x, terpadu	64 GB DDR (63 GB terlihat OS) + 24 GB GDDR6X, diskret
Interkoneksi	NVLink-C2C (5 × PCIe 5.0)	PCIe (CPU ↔ GPU)
CUDA	13.0, Driver 580.159.03, V13.0.88	13.0, Driver 580.65.06, V13.0.48
GCC	13.3.0 (Ubuntu 24.04)	13.3.0 (Ubuntu 24.04)
OS	Ubuntu 24.04 LTS (aarch64)	Ubuntu 24.04 LTS (x86_64)

B. Rancangan Kernel CUDA dan Penyelarasan Warp

Kami mengimplementasikan Layer 8 sebagai dua kernel CUDA yang ditulis tangan, bukan memakai pustaka umum seperti cuDNN [12]. Kami tidak mengklaim rancangan ini mengalahkan dekonvolusi berbasis cuDNN. Perbandingan itu belum diuji, dan kernel pustaka yang disetel baik sangat mungkin menang. Klaim kami lebih sempit: menulis pasangan kernel ini sendiri memberi kendali langsung atas tata letak buffer privat dan reduksi yang menjadi inti argumen kebenaran kami (Bagian VII).

Kernel dekonvolusi. Setiap blok thread memproses satu tile 2D dari peta fitur masukan. Untuk tiap kanal $c \in [0, 55]$, thread menghitung transposed convolution 9×9 dan menulis ke bidang kanal terisolasi pada `d_all_tmp`, terindeks $c \times (H_{out}W_{out}) + yW_{out} + x$.

Kernel reduksi spasial. Satu thread per piksel keluaran (y, x) menelusuri seluruh 56 bidang, menjumlahkannya, lalu menambahkan bias Layer 8:

$$\text{output}[y, x] = \left(\sum_{c=0}^{55} \text{d_all_tmp}[c, y, x] \right) + \text{bias}_8 \quad (1)$$

Penulisan kanal terisolasi selama dekonvolusi dan hanya dibaca selama reduksi, sehingga eksekusinya bebas race dan deterministik secara konstruktif.

GPU NVIDIA mengeksekusi thread dalam kelompok SIMD beranggota 32 yang disebut *warp* [6]. Blok 16×16 yang lazim

hanya menempatkan 16 thread pada dimensi X row-major, sehingga warp-warp berurutan melintasi baris yang tidak kontigu. Karena penentuan ukuran warp dan blok berpengaruh orde pertama pada throughput SIMT [14], kami mengevaluasi blok 32×8 (256 thread): menetapkan $B_x = 32$ menjamin seluruh 32 thread dalam satu warp mengakses double yang kontigu pada satu baris citra, sehingga coalescing maksimal.


IV. EVALUASI EKSPERIMENTAL

A. Metodologi Evaluasi

Beban kerjanya adalah 150 frame sekuens Suzie ($176 \times 144 \rightarrow 352 \times 288$, YUV420p). Setiap konfigurasi dijalankan 7 kali: run pertama dibuang sebagai pemanasan, run 2–7 dicatat sebagai rerata $\pm$ SD. Biner CPU dikompilasi dengan `gcc -fopenmp -O3` (tanpa `-march=native` maupun `-ffast-math`) memakai `#pragma omp parallel for` polos, sehingga penempatan thread mengikuti default statis `libgomp`; biner GPU memakai `nvcc -O3 -arch=native`. Kedua platform menjalankan GCC 13.3.0 dan CUDA 13.0. Seluruh aritmetika berpresisi ganda, menyamai baseline CPU agar perbandingan bit-exact sekuat mungkin; FP32 akan membuka peluang divergensi pembulatan bahkan untuk komputasi yang secara logis setara (konsekuensi throughput-nya di Bagian VI).

Berkas referensi: kami menjalankan V1 satu thread sekali untuk menghasilkan referensi deterministik. Karena ketiga varian mengimplementasikan algoritma identik dan hanya berbeda strategi eksekusi, berkas ini adalah uji determinisme internal; Bagian IV-C menilai kualitas rekonstruksi secara terpisah. Kebenaran dinilai lewat perbandingan byte (`cmp -l, diff_bytes = 0` untuk V1 terhadap V2 pada setiap konfigurasi grid) dan lewat PSNR/SSIM [8] yang dihitung dengan `ffmpeg`; nilai PSNR = ∞ pada V1/V2 secara logis setara dengan hasil perbandingan byte, sehingga kami melaporkannya sebagai *bit-exact*. PSNR/SSIM pada Tabel II adalah rerata seluruh komponen, sehingga kroma yang tidak tersentuh menariknya ke atas: kasus V0 terburuk pada RTX 4090 terbaca 23.0 dB/0.845 untuk seluruh komponen tetapi 21.5 dB/0.767 pada luminansi saja. Angka-angka itu justru *meremehkan* korupsinya, dan kami memberikan angka luminansi saja di tempat yang memang mementingkan besarnya korupsi.

V0 memburuk secara tidak monoton akibat race datanya: 13.8 dB pada GB10 (4 thread), dan 68.6 dB/0.99996 pada RTX 4090 (4 thread) sebelum runtuh ke 23.0 dB pada 32 thread. Kasus RTX-lah yang paling instruktif. Race yang hanya berbiaya 68.6 dB tak terlihat oleh pemeriksaan sekilas maupun ambang PSNR yang kasar, padahal ia sama tidak deterministiknya dengan kasus 13.8 dB, dan itu mendukung determinisme secara konstruktif ketimbang percaya bahwa hasil run “tampak baik-baik saja.” Tiga run V0 berturut-turut pada 32 thread merusak 4.75, 5.01 dan 5.04 juta dari 22.8 juta byte (21.34, 21.46, 21.63 dB PSNR-Y): tidak pernah menghasilkan keluaran yang sama dua kali. Gbr. 1 menampilkan satu frame.



Gbr. 1. Frame 26. Panel (b) adalah satu run V0 representatif dari tiga run – V0 adalah baseline naif yang murni CPU, tidak ada komputasi GPU yang terlibat. Run ini memakai 32 thread OpenMP pada CPU host Intel i9-14900K milik platform desktop kedua (yang GPU diskretnya tidak dipakai di sini) (21.5 dB PSNR-Y / 0.767 SSIM terhadap (a)); artefak scanline horizontalnya berasal dari penulisan tanpa sinkronisasi ke `img_flt_r_8`. Panel (c) dan (d) identik piksel demi piksel dengan (a) pada setiap konfigurasi yang diuji.

B. Penskalaan Kinerja dan Benchmark Akurasi

Tabel II menyajikan hasil untuk kedua platform pada berbagai jumlah thread, akurasi, dan konfigurasi grid GPU.

C. Kualitas Rekonstruksi terhadap Referensi Resolusi Tinggi

Karena tidak ada ground truth resolusi tinggi di dalam pipeline, kami membangunnya sendiri: Suzie di-downsample bicubic ke 88×72 , direkonstruksi pada skala 2, lalu dinilai terhadap citra aslinya, dengan upscaling bicubic dari masukan yang sama sebagai pembanding. Kami melaporkan luminansi saja, sebab hanya bidang Y yang melewati jaringan. FSRCNN mencapai 37.86 dB PSNR-Y dan 0.9665 SSIM-Y terhadap 35.69 dB dan 0.9532 milik bicubic, yakni selisih 2.17 dB atas 150 frame. Ini satu sekuens pada satu faktor skala, sebuah uji kewajaran dan bukan klaim tentang FSRCNN secara umum [2].

D. Biaya Determinisme, Dikuantifikasi

Tabel II mengukur biaya di sisi CPU secara langsung, yaitu selisih waktu wall-clock antara V0 (rawan race, tanpa privatisasi) dan V1 (terprivatisasi) pada jumlah thread yang sepadan: +18.2%, +17.6% dan +9.1% pada 1, 4 dan 20 thread di GB10, serta +9.2% dan +7.8% pada 1 dan 4 thread di RTX 4090. Selisih ini mengisolasi privatisasi, bukan perbedaan seberapa banyak pekerjaan yang di-thread. V0 dan V1 memparalelkan dekonvolusi yang sama, dan tahap reduksi V1 sendiri paralel atas piksel keluaran (Bagian II-C). Yang diukur selisih itu adalah penulisan dan pembacaan ulang 43.3 MiB buffer privat, bukan serialisasi sebuah tahap. Determinisme karena itu berbiaya 8–18% waktu wall-clock CPU. Titik-titik GB10 mengisyaratkan biayanya menurun begitu mesin jenuh, tetapi 1 dan 4 thread nyaris identik (18.2% vs. 17.6%), sehingga ini paling banter efek dua tingkat, bukan sebuah tren.

Di sisi GPU, instrumentasi per-kernel (Bagian IV-E) menempatkan biaya yang sama dalam satuan yang sebanding. Tahap reduksi adalah padanan overhead privatisasi di GPU, dan ia menyumbang 4.6% jendela event Layer 8 pada GB10 dan 0.6% pada RTX 4090. Porsi itu dihitung terhadap waktu Layer 8, bukan terhadap waktu wall-clock. Bila disetarakan dengan basis 8–18% milik CPU, reduksinya hanya menelan 0.55% dan 0.05% waktu ujung ke ujung, dan di situlah besarnya pergeseran itu benar-benar terlihat. Memori device puncak tetap 44.3 MiB termasuk padding alokator, di bawah 0.1%

TABEL II

KONFIGURASI KUNCI PADA KEDUA PLATFORM: KINERJA DAN DEVIASI TERHADAP REFERENSI DETERMINISTIK TERVERIFIKASI MASING-MASING PLATFORM. WAKTU WALL-CLOCK ADALAH RERATA $\pm$ SD ATAS 6 RUN TERUKUR DARI 7 KALI PENGULANGAN.

Varian	Konfigurasi / Thread	Waktu Wall (ms)	Percepatan vs. Serial	Percepatan vs. CPU Terbaik	Dev. dari Ref. (dB)	SSIM	Kernel L8 GPU (ms)
<i>GB10 (ASUS GX10), memori terpadu; tangga thread CPU 1–20</i>							
CPU V0 (Naif)	1 Thread	18,240.50 $\pm$ 228.82	1.00 $\times$	T/A	bit-exact	bit-exact	T/A
CPU V0 (Naif)	4 Thread (terburuk)	7,074.33 $\pm$ 90.21	2.58 $\times$	T/A	13.785	0.518246	T/A
CPU V0 (Naif)	20 Thread (Maks, tercepat)	6,346.33 $\pm$ 32.60	2.87 $\times$	T/A	25.751	0.838930	T/A
CPU V1 (Baseline)	1 Thread (Serial)	21,552.33 $\pm$ 298.07	1.00 $\times$	T/A	bit-exact	bit-exact	T/A
CPU V1	4 Thread (bdk. optimum RTX)	8,316.50 $\pm$ 58.06	2.59 $\times$	T/A	bit-exact	bit-exact	T/A
CPU V1 (Inti Maks)	20 Thread (terverifikasi tercepat)	6,921.83 $\pm$ 82.49	3.11 $\times$	T/A	bit-exact	bit-exact	T/A
GPU V2 (Hibrida)	Grid 16 $\times$ 16_256 (baseline)	4,935.67 $\pm$ 36.30	4.37 $\times$	1.40 $\times$	bit-exact	bit-exact	696.51 $\pm$ 1.78
GPU V2 (Grid Terbaik)	Grid 32 $\times$ 8_256	4,756.33 $\pm$ 30.71	4.53 $\times$	1.46 $\times$	bit-exact	bit-exact	533.19 $\pm$ 2.58
<i>Desktop RTX 4090, memori diskret; tangga thread CPU 1–32, latar GPU 4 thread</i>							
CPU V0 (Naif)	1 Thread	20,973.50 $\pm$ 36.30	1.00 $\times$	T/A	bit-exact	bit-exact	T/A
CPU V0 (Naif)	4 Thread (tercepat)	8,207.67 $\pm$ 247.16	2.56 $\times$	T/A	68.559	0.999957	T/A
CPU V0 (Naif)	32 Thread (Maks, terburuk)	26,388.67 $\pm$ 664.00	0.79 $\times$	T/A	23.006	0.845283	T/A
CPU V1 (Baseline)	1 Thread (Serial)	22,904.17 $\pm$ 86.90	1.00 $\times$	T/A	bit-exact	bit-exact	T/A
CPU V1 (Terbaik)	4 Thread (terverifikasi tercepat)	8,844.17 $\pm$ 132.68	2.59 $\times$	T/A	bit-exact	bit-exact	T/A
GPU V2 (Hibrida)	Grid 16 $\times$ 16_256 (baseline)	5,579.00 $\pm$ 166.61	4.11 $\times$	1.59 $\times$	bit-exact	bit-exact	437.06 $\pm$ 3.86
GPU V2 (Grid Terbaik)	Grid 32 $\times$ 8_256	5,435.50 $\pm$ 148.01	4.21 $\times$	1.63 $\times$	bit-exact	bit-exact	360.92 $\pm$ 7.22

Percepatan vs. Serial: baris CPU dibandingkan terhadap waktu 1 thread variannya sendiri; GPU V2 tidak punya waktu 1 thread, sehingga penyebutnya adalah waktu serial CPU V1 di platform tersebut (Bagian V-A juga melaporkannya terhadap waktu serial V0 yang lebih cepat dan bit-exact). *Percepatan vs. CPU Terbaik:* hanya untuk GPU V2, terhadap konfigurasi CPU V1 tercepat yang kebenarannya terverifikasi. *Dev./SSIM* diukur terhadap referensi deterministik masing-masing platform; “bit-exact” secara logis setara dengan hasil `cmp -l`, bukan pengukuran kualitas yang berdiri sendiri, dan angkanya adalah rerata seluruh komponen (Bagian IV-A). *Kernel L8 GPU:* rerata $\pm$ SD atas 6 run dari sweep profiling (Bagian IV-E); waktu kernel untuk tiga konfigurasi grid sisanya diberikan di Bagian VI-C.

dari kolom mana pun; kami menyebutnya hasil bandwidth dan paralelisme, bukan kapasitas, karena pada GB10 tidak ada VRAM terpisah yang bisa menjadi tujuan perpindahan buffer. Jarak antara kedua GPU bersifat arsitektural, bukan algoritmik: reduksinya terikat bandwidth dan L2 RTX 4090 menampung seluruh buffer privat. Determinisme secara konstruktif dengan demikian paling murah ketika kapasitas cache melampaui working set privatisasi. Dari situ lahir sebuah kaidah rancangan untuk menerapkan pola ini pada jaringan yang lebih besar: overhead menskala menurut seberapa jauh buffer melampaui last-level cache, bukan menurut jumlah kanal.

E. Rincian Waktu GPU Secara Rinci

Kami memasang profiling CUDA Event di dalam biner GPU dan menjalankan konfigurasi optimal (32 $\times$ 8_256) enam kali pada tiap platform (Tabel III).

Mengapa kami tidak melaporkan angka host ke device. Pencacah sisi host `h2d_ms` tidak dapat dibaca sebagai waktu transfer, dan kami mengecualikannya. Salinan-salinan tersebut di-issue di dalam jendela yang diukur `gpu_l8_ms`, dan sebuah blocking copy tidak dapat dimulai sebelum kernel yang diluncurkan sebelumnya tuntas, sehingga pencacah itu membebaskan waktu menunggu kernel kepada transfer. Sweep-nya memperjelas hal ini: `h2d_ms` bergeser 167 ms pada GB10 ketika yang berubah hanya *bentuk blok kernel*, padahal jumlah byte yang ditransfer identik sepanjang seluruh konfigurasi. Pencacah yang bergerak mengikuti bentuk blok pada jumlah byte tetap bukanlah pencacah yang mengukur byte. Sebagai gantinya kami melaporkan dekomposisi per-kernel.

Dua hasil menonjol, dan keduanya menunjuk ke arah berlawanan.

Kernel reduksi berbiaya 26.32 ms pada GB10 tetapi hanya 2.62 ms pada RTX 4090, jarak 10.0 $\times$ yang jauh lebih besar

TABEL III

RINCIAN PROFILING LAYER 8, 32 $\times$ 8_256, 150 FRAME (MS, RERATA $\pm$ SD ATAS 6 RUN)

Tahap Pipeline	GB10 (terpadu)	RTX 4090 (diskret)
CPU Layer 1–7	3,392.82 $\pm$ 21.62	4,624.50 $\pm$ 70.96
GPU Layer 8, jendela event	533.19 $\pm$ 2.58	360.92 $\pm$ 7.22
$\hookrightarrow$ deconv_kernel (56 $\times$)	424.07 $\pm$ 0.76	261.90 $\pm$ 3.09
$\hookrightarrow$ spatial_reduction (1 $\times$)	26.32 $\pm$ 1.02	2.62 $\pm$ 0.01
$\hookrightarrow$ transfer dalam jendela, jeda	127.65 $\pm$ 4.10	152.14 $\pm$ 0.36
Device ke Host	3.46 $\pm$ 0.06	16.42 $\pm$ 0.49
Tak terhitung (launch, I/O berkas)	821.20	469.33
Total Waktu Wall	4,750.67 $\pm$ 30.40	5,471.17 $\pm$ 76.17

Baris berindentasi mendekomposisi jendela event di atasnya dan bukan irisan waktu wall-clock tambahan. Baris-baris itu berasal dari biner terinstrumentasi terpisah yang pencatatan event-nya menggelembungkan jendela tersebut sebesar 8.4% (GB10) dan 15.4% (RTX 4090). Overhead itu terjadi *per launch*, sehingga hampir seluruhnya terkonsentrasi pada 8,400 launch `deconv_kernel`, bukan pada 150 launch reduksi: membagi pengelembungan dengan jumlah launch menghasilkan 5.34 μ s (GB10) dan 6.64 μ s (RTX 4090), dua platform independen yang sepakat dalam orde yang sama. Angka reduksinya karena itu hanya menggelembung sekitar 0.80 ms pada GB10, sekitar 3%, dan mendeflasi seluruh jendela secara seragam justru akan keliru menempatkan reduksi di atas puncak DRAM platformnya. Pencacah produksi `h2d_ms` sengaja tidak disertakan (lihat teks).

daripada keunggulan komputasi umum mana pun (dekonvolusinya hanya berbeda 1.6 $\times$). Reduksinya murni terikat bandwidth, membaca seluruh buffer privat 43.31 MiB sekali per frame, yakni 6.81 GB sepanjang 150 frame: 259 GB/s pada GB10, sekitar 95% dari puncak 273 GB/s kolom LPDDR5x-nya [17], dan 2,597 GB/s pada RTX 4090, lebih dari 2.5 $\times$ bandwidth GDDR6X kartu itu yang sebesar 1,008 GB/s. Mengoreksi overhead instrumentasi per-launch (Tabel III) menggeser angka GB10 ke 267 GB/s, tetap di bawah puncak, dan mendorong angka RTX 4090 makin jauh di atas puncaknya sendiri. Working set yang berada di DRAM tidak

mungkin menghasilkan angka seperti itu. Penjelasan yang wajar adalah L2 72 MB milik RTX 4090, yang cukup untuk menampung buffer tersebut, sehingga reduksinya sebagian besar dilayani dari cache sementara GB10 harus melakukan streaming dari memori terpadu mendekati puncak perangkat kerasnya. Kami menyodorkan ini sebagai pembacaan yang paling konsisten dengan bandwidth terukur, bukan sebagai fakta hasil profiling, sebab kami tidak merekam pencacah L2 (Bagian VII).

Transfer device ke host berjalan ke arah sebaliknya: 3.46 ms berbanding 16.42 ms, keunggulan $4.74\times$ bagi memori terpadu pada muatan yang identik (35.1 vs. 7.4 GB/s efektif). Inilah kontras memori terpadu versus diskret yang paling bersih dalam data kami, dan tidak seperti `h2d_ms`, pengukurannya berada di luar jendela event, setelah `cudaEventSynchronize`, tanpa eksekusi kernel yang bisa mencampurnya.

Memori device puncak tetap terbatas pada 45,382 KiB ($\approx$ 44.3 MiB) di kedua platform pada setiap konfigurasi, sekitar 1 MiB di atas minimum teoretis 43.3 MiB (Bagian II-C).

V. PEMBAHASAN DAN TEMUAN UTAMA

A. Percepatan terhadap CPU Berinti Penuh, dan Penyelarasan Warp

Kami melaporkan percepatan terhadap CPU V1, bukan V0, pada konfigurasi multi-thread: V1 bebas race pada setiap jumlah thread, sedangkan V0 hanya benar secara *kebetulan* pada 1 thread dan memburuk setelahnya. V0 sebenarnya pemenang waktu wall-clock mentah pada 20 thread (6,346.33 ms, yang hanya akan memberi $1.33\times$), tetapi keluarannya di titik itu tidak terverifikasi benar; kami menyebutkan angkanya ke-timbang menghilangkannya. GPU V2 ($32\times 8_{256}$) mencapai 4,756.33 ms (31.5 FPS), percepatan $1.46\times$ atas konfigurasi 20 thread CPU V1 (6,921.83 ms, hasil CPU tercepat yang kebenarannya terverifikasi).

Perbandingan serial menuntut kehati-hatian lebih, sebab kedua varian tidak berbagi baseline serial. Pada 1 thread V0 bersifat bit-exact sekaligus lebih cepat daripada V1 (18,240.50 vs. 21,552.33 ms) karena ia melewati privatisasi yang dibayar V1, dan itu menjadikannya baseline serial *bit-exact* tercepat yang tersedia: $3.84\times$ (GB10) dan $3.86\times$ (RTX 4090). Terhadap waktu serial V1, angkanya naik ke $4.53\times$ dan $4.21\times$, dilembungkan oleh penyebut yang lebih lambat, sehingga kami mengedepankan $3.84\times$. Baseline-nya bukan lawan yang lemah: inferensi CNN menskala baik pada klaster ARM big.LITTLE bila dijadwalkan dengan benar [3], dan inti-inti GB10 menskala mulus di sepanjang tangga thread tanpa keruntuhan seperti yang ditunjukkan RTX 4090 di atas 8 thread. GPU V2 juga konfigurasi yang paling stabil (± 30.71 berbanding ± 82.49 ms).

Beralih dari grid default 16×16 (696.51 ± 1.78 ms) ke grid selaras warp 32×8 (533.19 ± 2.58 ms) memangkas waktu kernel 23.4%, jarak yang jauh di luar variasi antar-run (SD 1.78 dan 2.58 ms). Kami mengaitkannya dengan coalescing: blok selebar 32 thread membuat setiap thread dalam satu warp menerbitkan permintaan ke dalam satu transaksi,

sedangkan blok selebar 16 memecahnya ke beberapa transaksi. Rincian per-kernel menguji hal ini lebih tajam daripada yang bisa dilakukan waktu wall-clock. Bentuk blok hanya memengaruhi `deconv_kernel`, sebab reduksinya diluncurkan satu dimensi. Jika coalescing memang mekanismenya, seluruh perolehan mestinya jatuh pada dekonvolusi. Dan memang demikian: `deconv_kernel` turun 24.9% (564.74 ke 424.07 ms) sementara reduksinya bergerak $+0.9\%$ (26.08 ke 26.32 ms), masih di dalam sebarannya sendiri. Ini tetap inferensi dari waktu, bukan pengukuran langsung efisiensi muat (Bagian VII).

B. Biaya Transfer dan Hukum Amdahl

Dibatasi dari atas, transfer bukanlah bottleneck pada kedua platform. Pada GB10, seluruh isi jendela event yang bukan eksekusi kernel berjumlah 127.65 ms, yakni 2.7% waktu wall-clock, ditambah 3.46 ms D2H; bahkan bila seluruh residu itu dibebankan sebagai transfer, yang jelas melebihi-lebihkan, porsinya tetap di bawah 3% pipeline. Residu RTX 4090 lebih besar baik secara absolut maupun sebagai porsi jendelanya (152.14 ms, 36.5% berbanding 22.1%), arah yang memang diprediksi PCIe versus NVLink-C2C, meski selisihnya cukup kecil sehingga kami tidak bertumpu padanya. Satu-satunya pengukuran transfer yang bersih sekaligus jelas asimetris adalah D2H.

Yang justru ditunjukkan Tabel III adalah langit-langit Hukum Amdahl [10]. Layer 8 kini tinggal 11.2% waktu wall-clock GB10 dan 6.6% pada RTX 4090, sementara CPU Layer 1–7, yang masih berjalan pada 20 dan 4 thread OpenMP alih-alih serial, menyumbang 71.4% dan 84.5%. Menggratiskan Layer 8 pun masih menyisakan pipeline RTX 4090 pada 93% waktu wall-clock saat ini, sehingga memindahkan Layer 1–7 adalah satu-satunya jalan tersisa menuju rekonstruksi di bawah satu detik; analisis Roofline [11] akan memastikan lebih dulu apakah pemindahan itu terikat komputasi atau memori. Sisa yang tak terhitung adalah peluncuran proses, I/O berkas dan konversi `uint8 $\leftrightarrow$ double` per frame, yang semuanya berjalan satu thread dan berada di luar wilayah terinstrumentasi.

VI. VALIDASI LINTAS PLATFORM PADA PERANGKAT KERAS GPU DISKRET

Untuk menguji apakah pendekatan ini berlaku umum di luar memori terpadu, kami mereplikasi eksperimennya pada desktop ber-GPU diskret (Tabel I). Dua perbedaan penting: memori CPU dan GPU terpisah melalui PCIe alih-alih berbagi satu kolam, dan CPU-nya heterogen (24 thread fisik / 32 logis pada P-core dan E-core) berhadapan dengan 20 inti homogen per tingkat milik GB10 yang tanpa SMT.

A. Penyesuaian Metodologi dan Percepatan GPU

Memakai ulang tangga thread GB10 beserta latar 20 thread justru menyedatkan di sini: waktu wall-clock runtuh di atas 8 thread hingga $\sim 3.5\times$ lebih lambat daripada optimum 4 thread, dan itu berulang pada tiga run penuh. Karena itu kami menyapu tangga yang sesuai topologi (1–32) dan memakai

konfigurasi CPU terbaik platform ini sendiri (4 thread) sebagai latar. Keruntuhan itu konsisten dengan pembagian P/E-core yang bertumpu pada Intel Thread Director sementara kolam OpenMP generik tidak membawa kendali afinitas [5], meski optimum 4 thread tidak cocok rapi dengan 8 P-core, sehingga kami tidak mengklaim penjelasan yang terkonfirmasi (Bagian VII). Hal ini insidental terhadap kontribusi kami, dan kami laporkan karena ia mengubah apa yang pantas disebut baseline CPU yang adil di sini. Dengan latar yang sudah dikoreksi, GPU V2 mencapai 5,435–5,579 ms (26.9–27.6 FPS), yakni $1.59\times$ – $1.63\times$ atas CPU V1 terbaik (4 thread, 8,844.17 ms). Angka itu bukan $4\times$ yang menggelembung karena dibandingkan terhadap waktu serial, atau terhadap run berjumlah thread tinggi yang sudah runtuh seperti CPU V0 pada 32 thread (Tabel II).

B. Kesamaan Bit Lintas Arsitektur


Bagian IV-A menegaskan bit-exactness *di dalam* tiap platform. Apakah keluaran GPU V2 identik *antar* keduanya merupakan pertanyaan yang lebih kuat. GB10 (host ARM, sm_121) dan RTX 4090 (host x86, sm_89) berbeda dalam ISA host dan mikroarsitektur GPU, sehingga keluaran identik-bit tidak dijamin hanya oleh kepatuhan IEEE-754 double: pembangkitan kode untuk dua target SM, kontraksi FMA, dan pustaka matematika masing-masing bisa menyimpang pada bit terakhir. Rantai perkakas di luar itu tergolong seragam (GCC 13.3.0 dan CUDA 13.0 pada keduanya), sehingga uji ini mengisolasi ISA dan mikroarsitektur alih-alih menumpuknya dengan perbedaan toolkit; klaim lintas-toolkit memerlukan eksperimennya sendiri. Menjalankan konfigurasi pemenang 32×8 pada keduanya, `cmp -l` melaporkan 0 byte berbeda dan digest SHA-256 keduanya cocok (8db2c07a...ca066b). Itulah bentuk terkuat dari klaim determinisme yang diajukan makalah ini.

C. Penyelarasan Warp Berlaku Umum Lintas Arsitektur GPU

Pada tingkat kernel, 32×8 tetap tercepat di GPU Ada Lovelace ini (360.92 ± 7.22 ms), 17.4% lebih cepat daripada 16×16 (437.06 ± 3.86 ms), yang menegaskan bahwa argumen coalescing pada Bagian III-B, sebagai konsekuensi granularitas warp 32 thread milik CUDA [6], merupakan sifat CUDA dan bukan sifat khas GB10. Pelokalannya pun bertahan: `deconv_kernel` turun 15.6% (310.32 ke 261.90 ms) sementara reduksinya tak berubah di 2.62 ms. Gbr. 2 membandingkan kelima konfigurasi grid pada kedua GPU, lengkap dengan error bar atas enam run. Pada tingkat *wall-clock*, kelimanya sulit dibedakan secara statistik (5,435–5,579 ms, error bar-nya bertumpang tindih) meski 32×8 secara nominal unggul di kedua metrik; keunggulan tingkat kernelnya hanya terlihat lewat profiling CUDA Event, dan itulah sebabnya instrumentasi tersebut penting.

D. Memori Non-Terpadu dan Presisi FP64

Memori CPU dan GPU di sini terpisah secara fisik melalui PCIe, tidak seperti kolam terpadu GB10 [20], [21]. Meski begitu, kernel Layer 8 platform inilah yang lebih cepat di



Gbr. 2. Waktu kernel Layer 8 GPU menurut konfigurasi grid, rerata $\pm$ SD atas 6 run. Grid selaras warp 32×8 (bergaris tebal) tercepat pada kedua arsitektur.

antara keduanya. Tabel III mengaitkannya dengan keunggulan komputasi dan cache pada Bagian IV-E, bukan dengan absennya biaya transfer: overhead PCIe/DMA [7] jelas terlihat pada residu dan angka D2H, tetapi ia kalah bobot. Karena itu kami memperkirakan keseimbangannya bergeser begitu working set melampaui L2 kartu ini. Presisi ganda juga menuntut harga di sini. Throughput FP64-nya secara arsitektural $1/64$ dari FP32, sehingga waktu kernel di atas dicapai dengan sumber daya komputasi dominannya menganggur, dan port FP32 sangat mungkin jauh lebih cepat dengan konsekuensi melemahnya bit-exactness menjadi sekadar toleransi numerik.

VII. KETERBATASAN DAN PEKERJAAN LANJUTAN

Celah terbesarnya adalah tidak adanya baseline GPU pembandingan: V2 hanya diadu dengan implementasi CPU, bukan dengan `atomicAdd`, kernel gather output-stationary, atau `cuDNN`. Dua penjelasan kami merupakan inferensi dari waktu, bukan pengukuran langsung. Penjelasan berbasis cache atas jarak $10\times$ pada reduksi akan tuntas bila ada pencacah hit-rate L2 dan sapuan working set melintasi batas L2; penjelasan coalescing, meski sudah terlokalisasi pada `deconv_kernel` sesuai prediksi, akan tuntas bila ada pencacah efisiensi muat dan lebar blok yang tidak selaras. Angka host ke device kami juga masih berupa batas atas yang memuat overhead peluncuran dan padding sisi host, yang dapat dipisahkan dengan pinned memory atau beberapa stream, meski D2H tidak terpengaruh. Tidak ada ablasi FP32 yang mengukur pertukaran antara percepatan dan bit-exactness, dan tidak ada eksperimen kendali `OMP_PROC_BIND` yang mengisolasi keruntuhan RTX 4090 dari kejenuhan bandwidth atau throttling termal. Terakhir, seluruh hasil memakai satu sekuens QCIF ke CIF sepanjang 150 frame, dengan kualitas rekonstruksi (Bagian IV-C) diukur pada satu faktor skala terhadap pengganti hasil down-sample bicubic, dan kroma direplikasi alih-alih direkonstruksi. Resolusi yang lebih tinggi akan menggeser rasio komputasi terhadap transfer dan mendorong buffer privat melewati L2

RTX 4090, yakni rezim yang paling menguji kaidah rancangan kami.

VIII. KESIMPULAN

Kami memperkenalkan kerangka reduksi spasial GPU untuk dekonvolusi Layer 8 FSRCNN dan mengevaluasinya pada dua platform yang berbeda secara arsitektural. Pada keduanya, varian CPU maupun GPU bersifat bit-exact terhadap referensi deterministik terverifikasi di setiap konfigurasi yang diuji, sementara akumulasi naif merusak keluaran secara tidak monoton, turun serendah 13.8 dB dan mencapai 68.6 dB yang nyaris tak terdeteksi, kegagalan yang justru lebih instruktif. Keluaran GPU bahkan identik-bit *antar* kedua platform, mencakup dua ISA host dan dua generasi GPU. Grid selaras warp 32×8 tercepat pada keduanya, dengan profiling per-kernel yang melokalisasi seluruh perolehan pada dekonvolusi sebagaimana dituntut penjelasan coalescing, dan percepatan terhadap konfigurasi CPU terbaik yang kebenarannya terverifikasi mencapai $1.46 \times$ (31.5 FPS) dan $1.63 \times$. Kedua asimetri platform berjalan ke arah berlawanan. Memori terpadu mengembalikan hasil $4.74 \times$ lebih cepat, sedangkan GPU diskret menjalankan reduksi yang terikat bandwidth $10.0 \times$ lebih cepat karena L2-nya menampung seluruh buffer privat yang harus di-streaming GB10 pada 95% puncak memorinya. Biaya determinisme dengan demikian lebih bergantung pada apakah working set privatisasi muat di last-level cache daripada pada algoritmanya, sebuah batas yang semestinya berlaku pula untuk jaringan mana pun yang menerapkan pola ini.

REFERENCES

- [1] Annisa, Adnan, and Z. Zainuddin, "Enhancing computational efficiency: transitioning from serial to parallel programming for low-to-high resolution video reconstruction using FSRCNN on AMP architecture," in *Proc. IEEE Int. Conf. Artif. Intell. Mechatron. Syst. (AIMS)*, 2025, pp. 1–8.
- [2] C. Dong, C. C. Loy, and X. Tang, "Accelerating the super-resolution convolutional neural network," in *Proc. ECCV*, 2016, pp. 391–407.
- [3] S. Wang *et al.*, "High-throughput CNN inference on embedded ARM big.LITTLE multicore processors," *IEEE TCAD*, vol. 39, no. 10, pp. 2254–2267, 2020.
- [4] C. Bilbao, J. C. Saez, and M. Prieto-Matías, "Flexible system software scheduling for asymmetric multicore systems with PMCSched: a case for Intel Alder Lake," *Concurr. Comput. Pract. Exper.*, vol. 35, no. 25, e7814, 2023.
- [5] A. E. Eichenberger *et al.*, "The design of OpenMP thread affinity," in *IWOMP*, LNCS 7312, 2012, pp. 15–28.
- [6] NVIDIA Corp., *CUDA C++ Programming Guide*. [Online]. Available: docs.nvidia.com/cuda/cuda-c-programming-guide/
- [7] Y. Go *et al.*, "APUNet: revitalizing GPU as packet processing accelerator," in *Proc. USENIX NSDI*, 2017, pp. 83–96.
- [8] Z. Wang *et al.*, "Image quality assessment: from error visibility to structural similarity," *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, 2004.
- [9] C. Dong *et al.*, "Learning a deep convolutional network for image super-resolution," in *Proc. ECCV*, 2014, pp. 184–199.
- [10] G. M. Amdahl, "Validity of the single processor approach to achieving large scale computing capabilities," in *Proc. AFIPS*, 1967, pp. 483–485.
- [11] S. Williams, A. Waterman, and D. Patterson, "Roofline: an insightful visual performance model for multicore architectures," *Commun. ACM*, vol. 52, no. 4, pp. 65–76, 2009.
- [12] S. Chetlur *et al.*, "cuDNN: efficient primitives for deep learning," arXiv:1410.0759, 2014.
- [13] K. Serebryany and T. Iskhodzhanov, "ThreadSanitizer: data race detection in practice," in *Proc. WBAI*, 2009, pp. 62–71.
- [14] A. Lashgar, A. Baniasadi, and A. Khonsari, "Warp size impact in GPUs: large or small?," in *Proc. GPGPU-5*, 2012, pp. 27–32.
- [15] V. Dumoulin and F. Visin, "A guide to convolution arithmetic for deep learning," arXiv:1603.07285, 2016.
- [16] NVIDIA Corp., "NVIDIA puts Grace Blackwell on every desk and at every AI developer's fingertips," NVIDIA Newsroom, Jan. 2025. [Online]. Available: nvidianews.nvidia.com/news/nvidia-puts-grace-blackwell-on-every-desk-and-at-every-ai-developers-fingertips
- [17] ASUSTeK Computer Inc., *ASUS Ascent GX10 Datasheet*, v8, 2025. [Online]. Available: dlcdnwebimg.asus.com/files/media/202506/5c0fb57c-4e48-4e96-8c97-04bf8df2677c/asus-ascent-gx10-datasheet.pdf
- [18] Arm Ltd., "DynamIQ technology." [Online]. Available: arm.com/technologies/dynamiq
- [19] NVIDIA Corp., *NVIDIA Ada GPU Architecture*, Whitepaper V2.02, 2022.
- [20] NVIDIA Corp., "Grace Hopper Superchip architecture in-depth," NVIDIA Developer Blog, 2022.
- [21] J. Wahlgren *et al.*, "Dissecting CPU-GPU unified physical memory on AMD MI300A APUs," in *Proc. IEEE IISWC*, 2025.